

2022秋季 学院路校区(凸优化与近似)

最优化方法 第3次作业

提交日期：2022 年10 月27日周四课前

2022 年 10 月 9 日

Algorithm 1 Conjugate gradient method for minimizing $f(x) = \frac{1}{2}x^T Ax - b^T x$

```
1: Given  $x^{(0)}$ , and compute  $r^{(0)} = Ax^{(0)} - b$ ;  
2: set  $p^{(0)} = -r^{(0)}$ ,  $k = 0$ ;  
3: while  $\|r^{(k)}\| > \epsilon$  do  
4:   set  $d = Ap^{(k)}$ ;  
5:   set  $\alpha_k = \frac{r^{(k)T} r^{(k)}}{p^{(k)T} d}$ ;  
6:   set  $x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}$ ;  
7:   set  $r^{(k+1)} = r^{(k)} + \alpha_k d$ ;  
8:   set  $\beta_{k+1} = \frac{r^{(k+1)T} r^{(k+1)}}{r^{(k)T} r^{(k)}}$ ;  
9:   set  $p^{(k+1)} = -r^{(k+1)} + \beta_{k+1} p^{(k)}$ ;  
10:  set  $k = k + 1$ ;  
11: end while  
12: return  $x^{(k)}$  as  $x^*$ .
```

1. 利用共轭梯度法极小化二次函数 $f(x) = 10x_1^2 + x_2^2$ ，其中 $x^{(0)} = (0.1, 1)^T$.
验证：经过 n 次一维搜索后的二次终止性.
2. (选做题) 利用共轭梯度法的迭代形式直接证明共轭梯度法的以下性质对 $k = 1$ 成立. 设 m 是算法1中使 $r^{(m)} \neq 0$ 的最大整数, 则 $m \leq n$; 且对所有 $k = 1, \dots, m$, 下列事实成立:

$$p^{(k)T} A p^{(i)} = 0, \quad i = 0, 1, \dots, k-1 \quad (1a)$$

$$r^{(k)T} r^{(i)} = 0, \quad i = 0, 1, \dots, k-1 \quad (1b)$$

$$p^{(k)T} r^{(k)} = -r^{(k)T} r^{(k)} \quad (1c)$$

$$\text{span}\{r^{(0)}, r^{(1)}, \dots, r^{(k)}\} = \text{span}\{r^{(0)}, Ar^{(0)}, \dots, A^k r^{(0)}\} \quad (1d)$$

$$\text{span}\{p^{(0)}, p^{(1)}, \dots, p^{(k)}\} = \text{span}\{r^{(0)}, Ar^{(0)}, \dots, A^k r^{(0)}\}. \quad (1e)$$

上述性质中, (1a)-(1b)分别说明共轭梯度法所产生的搜索方向是共轭的, 梯度是正交的; (1c)说明每一步产生的搜索方向是下降的; (1d)-(1e)说明每个搜索方向和梯度皆包含于 $\mathbf{r}^{(0)}$ 的 k 阶Krylov子空间, 即

$$\mathcal{K}_k(\mathbf{A}, \mathbf{r}^{(0)}) := \text{span}\{\mathbf{r}^{(0)}, \mathbf{A}\mathbf{r}^{(0)}, \dots, \mathbf{A}^k\mathbf{r}^{(0)}\}.$$

这个概念在分析共轭梯度法的收敛速度方面有非常重要的应用; 共轭梯度法也是解系数矩阵是对称正定的线性方程组的最基本的Krylov子空间法.

3. 参考网页<https://ee227c.github.io/code/lecture4.html>, 自主学习“梯度法的应用”, 针对每个应用问题, 整理出:

- 应用问题的描述, 及对应的优化模型, 并给出模型中涉及的数据、变量和参数的解释.
- 目标函数是否是凸函数或者强凸函数? 为什么?
- 求出目标函数的梯度. 是 β -光滑的吗? 如果是, 给出具体的光滑性参数 β .