

2022秋季 学院路校区(凸优化与近似)

最优化方法 第5次作业

提交日期：2022年11月24日周四课前

2022年11月9日

1. (将点到仿射集的距离建模为凸二次规划问题. 特别地, 当所给仿射集是 $n-1$ 维的, 即为超平面时, 就是中学所学知识“点到直线的距离”和“点到平面距离”公式的推广.) 考虑点 $\mathbf{x}^{(0)}$ 到多面集 $\{\mathbf{x} \in \mathbb{R}^n : \mathbf{A}^T \mathbf{x} = \mathbf{b}\}$ (其中 \mathbf{A} 是列满秩的) 的最短距离问题. 它可以表述为二次规划

$$\begin{aligned} & \text{minimize} && \frac{1}{2}(\mathbf{x} - \mathbf{x}^{(0)})^T(\mathbf{x} - \mathbf{x}^{(0)}) \\ & \text{subject to} && \mathbf{A}^T \mathbf{x} = \mathbf{b}. \end{aligned}$$

这个问题是凸规划吗? 利用几何最优性条件证明该问题的最优解

$$\mathbf{x}^* = \mathbf{x}^{(0)} - \mathbf{A}(\mathbf{A}^T \mathbf{A})^{-1}(\mathbf{A}^T \mathbf{x}^{(0)} - \mathbf{b}).$$

说明当 $\mathbf{A} = \mathbf{a} \neq \mathbf{0}$ 是一个列向量, $b \in \mathbb{R}$ 时, 从 $\mathbf{x}^{(0)}$ 到超平面 $\mathbf{a}^T \mathbf{x} = b$ 的最短距离是 $\frac{|\mathbf{a}^T \mathbf{x}^{(0)} - b|}{\|\mathbf{a}\|_2}$.

2. [最优性条件] 给出以下问题最优解的充分必要条件.

(a) 已知 $y \in \mathbb{R}^n$. 考虑问题

$$\begin{aligned} & \text{minimize}_{x \in \mathbb{R}^n} && \frac{1}{2} \|y - x\|_2^2 \\ & \text{subject to} && x \geq 0, \sum_{i=1}^n x_i = 1. \end{aligned}$$

(b) 设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是凸的可微函数, 已知 $A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$. 考虑问题

$$\begin{aligned} & \text{minimize}_{x \in \mathbb{R}^n} && f(x) \\ & \text{subject to} && Ax \leq b. \end{aligned}$$

3. [体会写对偶问题时其中集合约束选取的灵活性] 考虑问题

$$\begin{aligned} & \underset{\mathbf{x} \in \mathbb{R}^n}{\text{minimize}} && f(\mathbf{x}) = \mathbf{c}^T \mathbf{x} \\ & \text{subject to} && \mathbf{A}\mathbf{x} \geq \mathbf{b} \\ & && \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

分别基于集合约束 $\Omega = \{\mathbf{x} \in \mathbb{R}^n \mid \mathbf{x} \geq \mathbf{0}\}$ 和 $\Omega = \mathbb{R}^n$ 写出该问题的对偶问题.

4. 支撑向量机中相关优化问题的若干分析.

给定训练数据:

$$(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_l, y_l),$$

其中 $\mathbf{x}_i \in \mathbb{R}^d, y_i \in \{-1, 1\}$. 假设数据几乎线性可分离, 则支撑向量机中求解最优分离超平面的优化问题是

$$\begin{aligned} & \underset{\mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}}{\text{minimize}} && \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^l \xi_i \\ & \text{subject to} && y_i(\mathbf{w}^T \mathbf{x}_i - b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, l \\ & && \xi_i \geq 0, \quad i = 1, 2, \dots, l, \end{aligned} \quad (1)$$

其中 C 是折中参数. 设该优化问题的最优解是 \mathbf{w}^*, b^* , 则最终的分类超平面是

$$(\mathbf{w}^*)^T \mathbf{x} = b^*,$$

最终的分类器是

$$g(\mathbf{x}) = \text{sgn}((\mathbf{w}^*)^T \mathbf{x} - b^*).$$

该模型的直观含义是使得两类几乎线性可分数据之间的 $\text{Margin} = \frac{1}{\|\mathbf{w}\|_2}$ 尽可能地大, 从而使分类器具备更强的推广能力, 同时使经验误差 $\sum_{i=1}^l \xi_i$ 尽可能地小.

针对约束优化问题(1)进行以下分析:

- 写出(1)的Lagrange函数.
- 求出(1)的对偶函数.
- 写出(1)的Lagrange对偶问题, 并指出如何由对偶问题的最优解确定(1)的最优解中的 \mathbf{w} .
- 写出优化问题(1)的KKT条件.
- 比较(c)和(d)的结果. 并给出所观察到的现象的一个可能的解释.

5. [凸共轭] 对任意函数 $f: C \subset \mathbb{R}^n \rightarrow \mathbb{R}$, 定义其凸共轭 f^* 为

$$f^*(y) = \sup_{x \in C} (y^T x - f(x)). \quad (2)$$

f^* 的定义域取为集合 $D = \{y \in \mathbb{R}^d : f^*(y) < \infty\}$.

(1) 求 f^* 和 D , 若

(a) $f(x) = 1/x, C = (0, \infty)$,

(b) $f(x) = \frac{1}{2}\|x\|_2^2, C = \mathbb{R}^n$,

(c) $f(x) = \log \sum_{j=1}^n \exp(x_j), x = (x_1, \dots, x_n), C = \mathbb{R}^n$,

下面假设 f 为严格凸可微函数, 且 $C = \mathbb{R}^d$.

(2) 证明 $\forall x \in C, f(x) \geq f^{**}(x)$ 成立.

(3) 证明(2)中的上确界在满足 $\nabla f(x^*) = y$ 的 x^* 处取到.

(4) 回想 $D_f(\cdot, \cdot)$ 表示关于 f 的Bregman散度. 证明

$$D_f(x, y) = D_{f^*}(\nabla f(y), \nabla f(x))$$

6. 考虑问题

$$\begin{aligned} & \text{minimize} && x_1^2 + x_2^2 \\ & \text{subject to} && x_1 + x_2 - 1 = 0. \end{aligned}$$

(a) 这个问题是凸规划吗?

(b) 写这个问题的几何最优性条件, 求出最优解和对应的Lagrange乘子.

(c) 求出这个问题的Lagrange对偶问题, 并求解.

(d) 设 $\eta = 2, \lambda_1 = 0$. 分别给出用对偶上升法和乘子法求解所给问题得到的迭代点 λ_2 .

(e) 比较(d)中两种方法得到的 λ_2 与(c)中得到的对偶最优解的远近.